DOCUMENT TECHNIQUE

PING 62

Table des matières

1. L'ÉTAT DE L'ART 2
Densefusion 2
CosyPose ECCV 3
2. Modèles vision 4
YOLO V11 4
YOLO V11 OBB 5
YOLO V11 Segmentation 5
YOLO V11 OBB + Labellisation des côtés 6
YOLO V11 OBB double modèle 8
3. Algorithmes 8
Sans orientation, se positionner au-dessus du centre 8
Avec orientation 9
Orientation et déplacement en 2 temps séparés 9
Approche puis réestimation pour prise en 5 étapes 10
Vérification de Faisabilité (Anti-Collision) : 10
Nudge pour résoudre les situations impossibles 11
Ajout des angles en X et Y 11
Double caméra avec "contrôle qualité" 12
MoveJ et MoveL rotation/déplacement (4 étapes) 12
Explication du calcul "Hors Vision" (Score = 0) 13
4. Axes d'amélioration du TP : 14
Installation des librairies : 14
Fiche de TP : 14
Calibration Robot : 14
Guides pour les librairies à utiliser : 14
Nombre d'étudiants par groupe : 15
Bibliographie 15

1. L'ÉTAT DE L'ART

Densefusion

DenseFusion est une méthode d'estimation de pose 6D à partir d'images RGB-D, conçue pour exploiter efficacement la complémentarité entre couleur et profondeur. Elle traite séparément les données RGB et profondeur, puis les fusionne de manière dense et pixel par pixel afin d'extraire des caractéristiques géométriques et visuelles riches.
La pose de l'objet est ensuite estimée directement à partir de cette représentation fusionnée.

Un raffinement itératif end-to-end est intégré pour améliorer la précision de la pose tout en conservant un temps de calcul proche du temps réel.
Les résultats montrent que DenseFusion surpasse l'état de l'art sur les jeux de données YCB-Video et LineMOD, et est validée sur un robot réel pour la préhension d'objets.



Image 1 : Réseau profond d'end-to-end pour la 6D

Densefusion est une méthode d'estimation de pose 6D basée sur le deep learning, conçue spécifiquement pour :

1. Le dévracage
2. Les occlusions
3. Les objets industriels empilés

Avantages :

1. Excellente précision
2. Très robuste au dévracage
3. Très utilisée en robotique industrielle

Limites :

Elle nécessite une caméra RGB-D, ce qui impose un capteur spécifique. L'apprentissage doit être réalisé par type d'objet, ce qui demande des données. Le réseau est plus complexe et coûteux en calcul qu'une approche géométrique simple.

CosyPose ECCV

CosyPose est une méthode d'estimation de pose 6D permettant de localiser plusieurs objets connus à partir d'images RGB, en configuration mono-vue ou multi-vues.
Elle génère d'abord des hypothèses de pose 6D pour chaque objet à partir d'une vue unique, puis associe ces hypothèses entre différentes images afin d'estimer conjointement les poses des objets et des caméras.
La méthode gère explicitement les symétries des objets et ne nécessite pas de mesures de profondeur.

Un raffinement global de la scène, basé sur un ajustement de type bundle adjustment, permet d'améliorer la cohérence des poses en minimisant l'erreur de reprojection. Les résultats montrent que CosyPose surpasse l'état de l'art sur les jeux de données YCB-Video et T-LESS en estimation de pose 6D mono-vue et multi-vues.

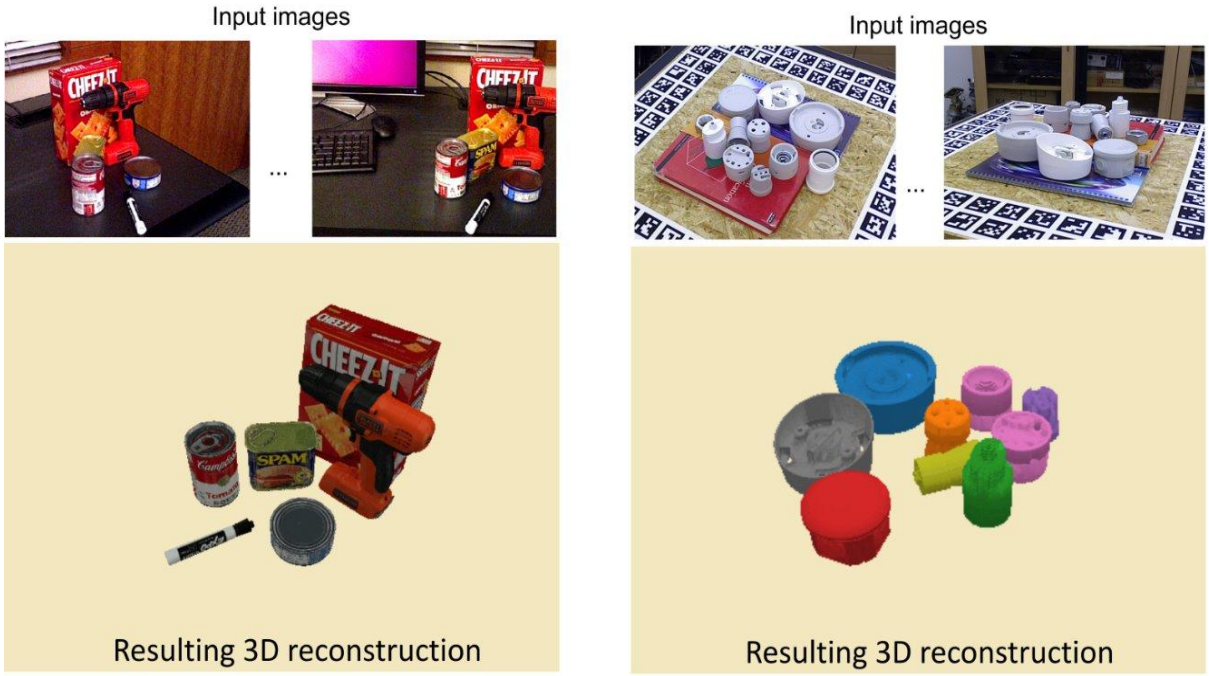


Image 2 : Résultats de l'estimation de pose 6D par CosyPose

Avantages :

1. Fonctionne en RGB seul
2. Pipeline modulaire
3. Très précis après raffinement

Limites :

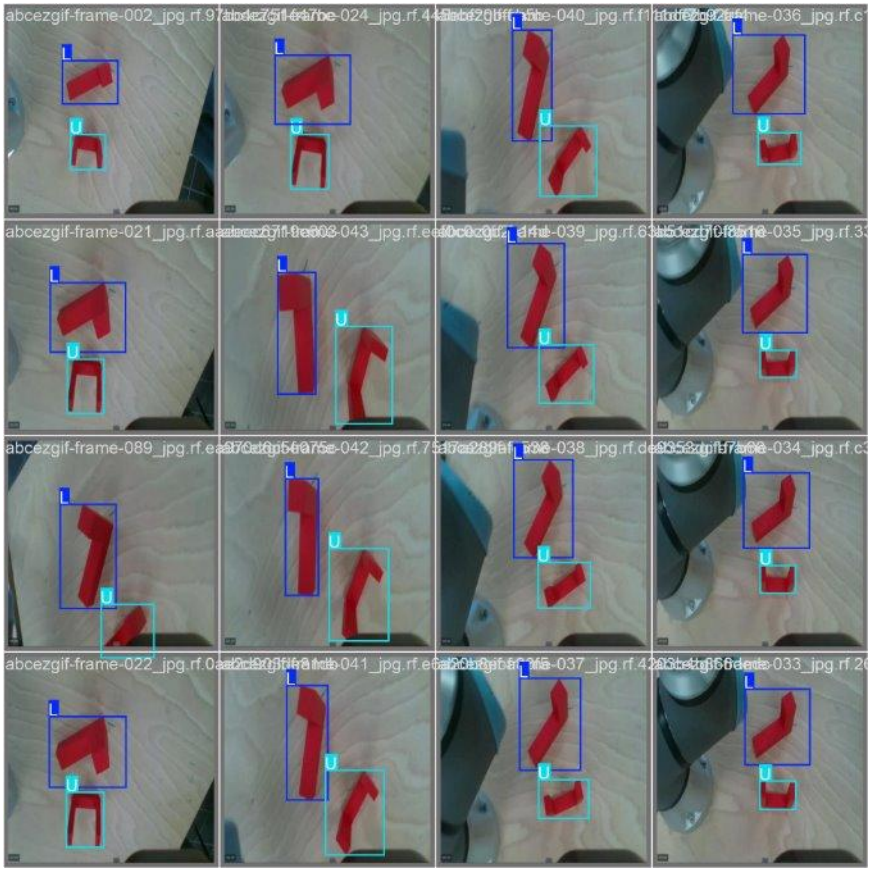
Le raffinement par rendu rend le temps de calcul élevé, peu adapté au temps réel. La méthode est complexe à mettre en œuvre (rendu 3D, synchronisation). Pour des objets industriels en U et L peu texturés, elle est moins robuste que DenseFusion.

2. Modèles vision

Avant de choisir notre modèle, nous avons labellisé 800 images comportant un U et un L grâce à Roboflow pour tester différentes options de modèle et choisir celui qui serait le plus adapté à notre cas.

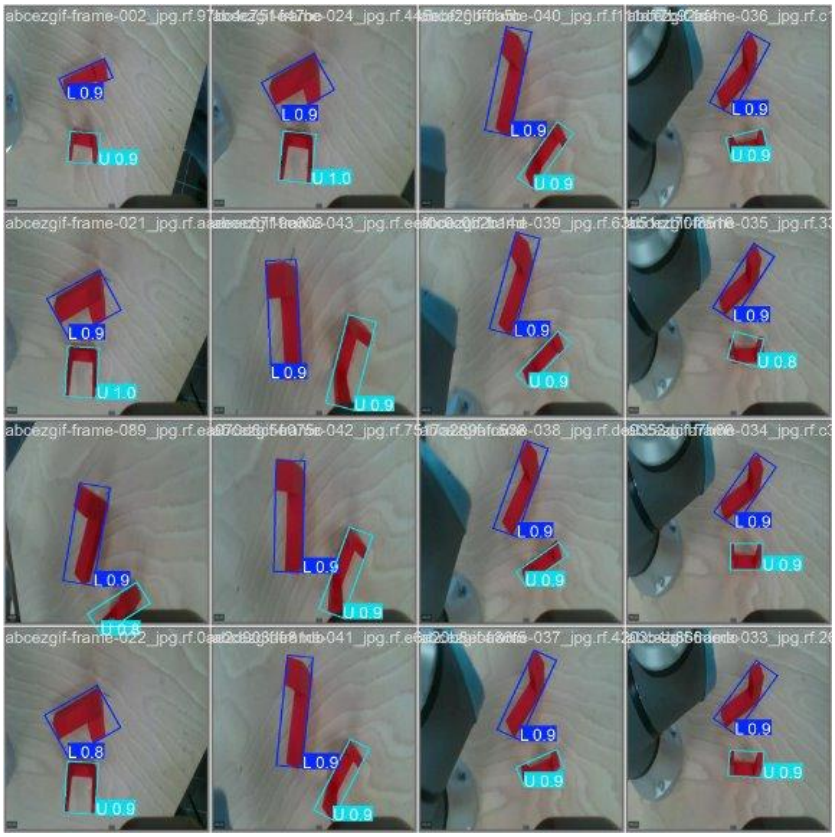
YOLO V11

Notre première approche a été d'essayer le modèle YOLO V11 simple pour voir les résultats en inférence. Les boites permettent de différencier les U des L mais les boites commencent à se superposer quand les pièces sont proches ou partiellement imbriquées. Le niveau de détection n'est pas suffisant pour définir un point de préhension.



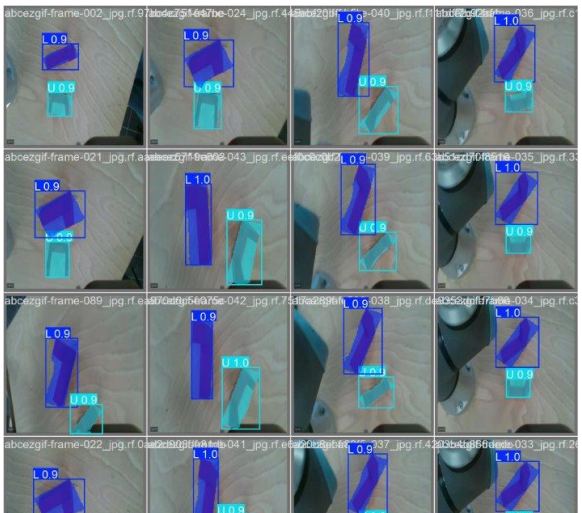
YOLO V11 OBB

Ensuite, nous avons testé une nouvelle approche avec YOLO V11 OBB qui nous permet d''avoir des boites orientées : les boites sont donc plus proches des contours des pièces. Cependant, une boite ne convient pas à la forme des pièces à manipuler : il est difficile de déterminer un point ou une zone de préhension pour nos pièces : le centre des boites est vide, il nous faut plus de précision.

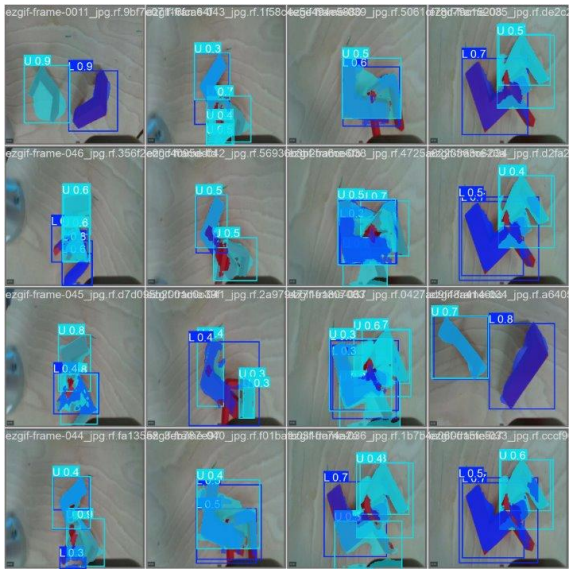


YOLO V11 Segmentation

Pour répondre au besoin mis en exergue par nos deux précédents essais, nous avons essayé le modèle YOLO V11 seg, qui permet d''identifier des formes complexes. Plutôt qu''une boite sur l'image nous aurons un masque sur la pièce qui épouse ses contours. Avec nos 800 images, nous avons eu un résultat de piètre qualité avec des images "simples" à identifier où chaque pièce est bien séparée des autres. En inférence avec des pièces superposées, le résultat était simplement inexploitable. Avant

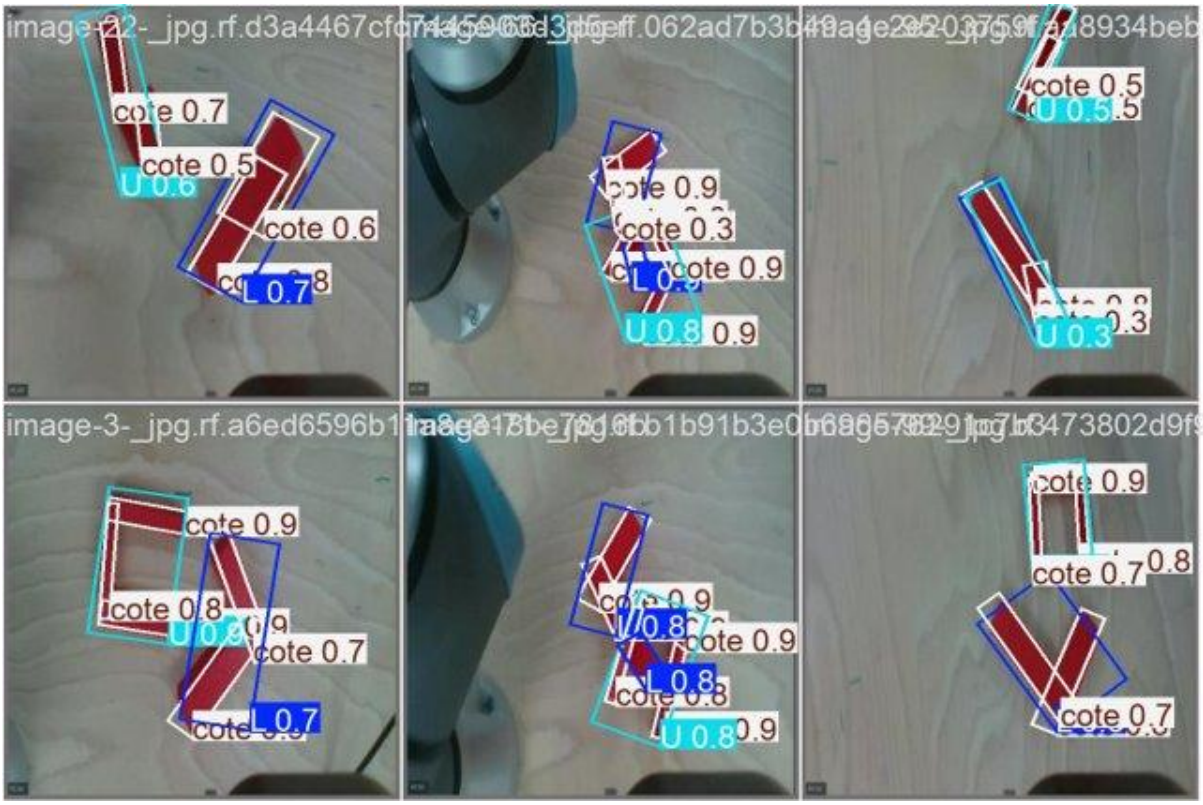


d’essayer avec un dataset plus grand, nous avons testé la prochaine idée.

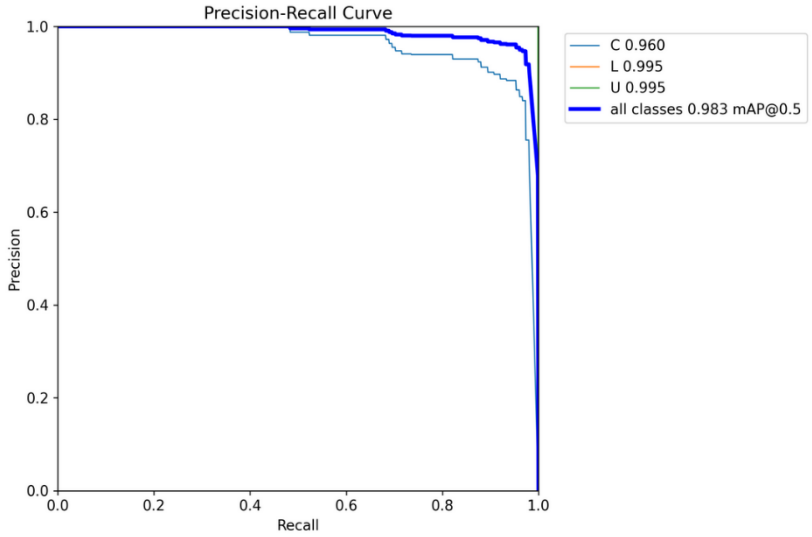


YOLO V11 OBB + Labellisation des côtés

La piste suivante que nous avons explorée a été celle d’une nouvelle labellisation à exploiter avec YOLO V11 OBB. Dans cette nouvelle labélisation, nous avons identifié chacun des côtés ainsi que le type de chaque pièce (U ou L). Avec 50 images labélisé de cette façon, nous avons pu constater des résultats prometteurs.

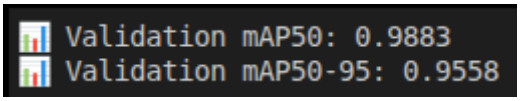


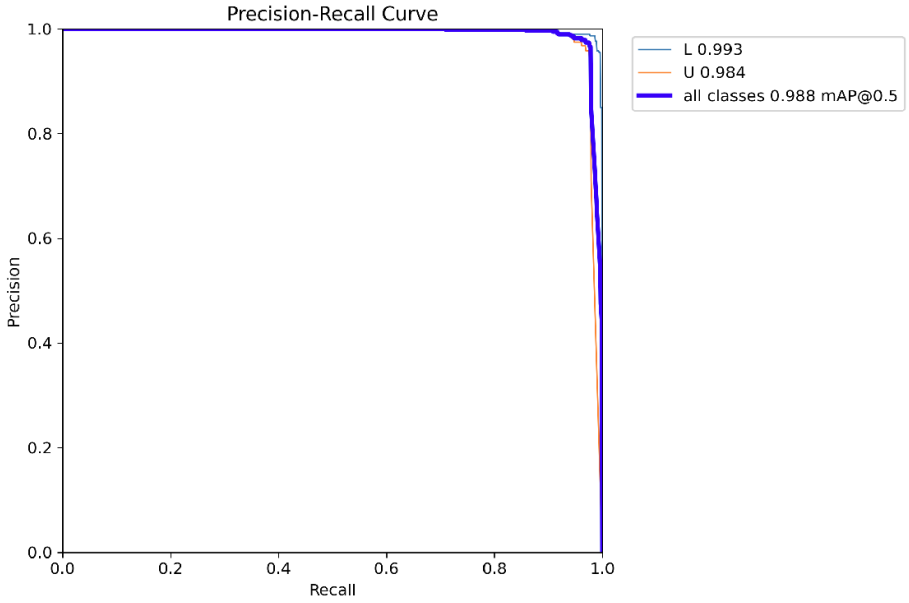
Nous avons pu constater que même avec ce dataset très limité, cette méthode nous permet d'identifier les côtés (donc les prises possibles) ainsi que le type de pièce. Nous avons donc retenu cette idée pour la suite du projet et labellisé les 800 images avec les côtés et les types.



YOLO V11 OBB double modèle

Plus tard dans notre projet, nous avons été confrontés à de nouvelles problématique lié au nombre de pièce et à l'occlusion des pièces qui en découle. Pour répondre à cette problématique, nous avons choisi de faire un nouvel entraînement pour la différentiation des U et des L uniquement, le précédent modèle étant suffisant pour identifier les côtés. Nous avons donc labellisé 1200 images avec des scènes différentes, depuis plusieurs angles différents pour représenter un maximum de situations. Sur chacune des images nous avons identifié le type de pièce uniquement, le précédent modèle étant suffisant pour les côtés. Cette solution hybride nous a permis d'obtenir les meilleurs résultats avec un temps de labellisation limité.





3. Algorithmes

Sans orientation, se positionner au-dessus du centre

Dans la phase préliminaire du développement, une stratégie de saisie simplifiée a été mise en œuvre. Celle-ci se caractérise par un positionnement du robot fondé exclusivement sur les coordonnées du centre géométrique de la détection, en faisant abstraction de l'orientation angulaire de la pièce. Le principe opérationnel consiste à projeter le centre de la boîte englobante (bounding box) directement dans le repère cartésien du robot. Ce dernier exécute alors une translation pour se placer à l'aplomb de la cible (axe Z), avant d'effectuer une descente et une tentative de préhension purement verticale.

Bien que cette méthode présente l'avantage d'une implémentation rapide et d'une faible charge de calcul, elle a rapidement montré ses limites opérationnelles. Si elle permet de s'affranchir des erreurs d'estimation d'angle, elle s'avère inadaptée à la manipulation de pièces aux géométries complexes, telles que les formes en U ou en L. L'absence d'alignement des mors de la pince avec l'axe principal de l'objet engendre un taux d'échec élevé lorsque la pièce est mal orientée et accroît significativement le risque de collision avec les objets adjacents. En conséquence, cette approche a servi uniquement de référence (baseline) pour l'évaluation des performances, avant d'être abandonnée au profit de méthodes vectorielles intégrant l'orientation de la pièce.

Avec orientation

Une seconde stratégie a été expérimentée, consistant à planifier une trajectoire unique et fluide depuis la position de repos (Home) jusqu'à la cible. Dans cette configuration, le contrôleur du robot intègre simultanément les coordonnées cartésiennes (X, Y, Z) et l'orientation angulaire requise, tentant de rallier le point de saisie sans étape intermédiaire.

Cependant, cette méthode s'est heurtée à des contraintes cinématiques critiques. L'obligation pour le robot d'atteindre une position spatiale précise tout en opérant une rotation importante du poignet (par exemple 90°) force les articulations intermédiaires, notamment le coude, à effectuer de vastes mouvements compensatoires pour éviter les singularités mathématiques. Cette imprévisibilité de l'enveloppe de travail dynamique devient problématique dans un contexte de dévracage, où le coude risque de renverser la pile d’objets. Par ailleurs, le couplage d'une rotation complexe durant la phase de descente tend à dégrader la précision linéaire de l'effecteur final, compromettant la fiabilité de la préhension.

Orientation et déplacement en 2 temps séparés

Afin de pallier les instabilités cinématiques observées lors des tentatives de trajectoires directes, cette méthode adopte une stratégie de dissociation stricte entre le déplacement spatial et l'orientation de l'effecteur. Le principe fondamental repose sur la segmentation du mouvement d'approche en étapes distinctes, isolant la gestion des axes de translation de celle des axes de rotation.

Concrètement, la séquence opératoire débute par le positionnement du robot à une hauteur de sécurité, à l'aplomb de la pièce détectée, sans modification de l'angle du poignet. Une fois cette position intermédiaire atteinte et stabilisée, le robot procède exclusivement à la réorientation de l'outil pour aligner les mors de la pince avec l'axe

principal de l'objet. Ce n'est qu'une fois cet alignement angulaire validé que la descente verticale finale est amorcée pour effectuer la saisie.

Cette segmentation offre l'avantage majeur de rendre les trajectoires du bras parfaitement prévisibles, éliminant quasi totalement les risques de singularités et les mouvements parasites du coude potentiellement dangereux pour l'environnement. Si cette décomposition induit une légère augmentation du temps de cycle global et reste dépendante de la fixité de l'objet durant la manœuvre, elle garantit une précision linéaire optimale lors de la phase critique de contact. En raison de sa robustesse, cette architecture séquentielle a été retenue comme socle fondamental pour l'élaboration des stratégies de préhension avancées.

Approche puis réestimation pour prise en 5 étapes

Lorsqu'une pièce candidate est identifiée comme accessible et libre d'obstacles, le cycle de préhension est initié par une approche linéaire (moveL) vers une position d'attente située à la verticale de la cible. Cette phase préliminaire assure le positionnement du robot selon les axes X et Y, tout en opérant simultanément l'orientation de l'effecteur. L'objectif est d'aligner rigoureusement l'axe des mors du préhenseur avec l'orientation principale de l'objet détecté, garantissant ainsi une prise optimale.

Une fois l'alignement planimétrique validé, le robot engage une descente de précision selon l'axe Z jusqu'au point de contact. Cette translation verticale est contrôlée pour minimiser les risques de collision avec la pièce ou son environnement immédiat. La séquence se conclut par l'actionnement de la fermeture de la pince, immédiatement suivi d'une étape de validation par rétroaction positionnelle. Le système interroge l'écartement final des mors : si la valeur relevée se situe hors de la plage nominale attendue (par exemple, une ouverture inférieure à 10 ou supérieure à 240 unités), la prise est considérée comme manquée (« VIDE »), ce qui déclenche l'interruption du cycle pour ce candidat.

Vérification de Faisabilité (Anti-Collision) :

Pour vérifier la faisabilité nous simulons des ”doigts“ : Création d'un rectangle virtuel représentant la pince ouverte. Grace à cela nous pouvons vérifier si le rectangle de la pince intersecte d'autres objets détectés. Nous vérifions aussi la collision au niveau de la profondeur (Z). C‘est à dire que nous vérifions si l'espace entre les doigts est libre (pas d'obstacle en hauteur). À la suite de tous ces calculs nous calculons un

”Scoring“ qui symbolise le meilleur candidat pour la prise. Les candidats valides sont classés selon leur hauteur (Z) et leur accessibilité.

Le système ne considère pas le robot comme un simple point dans l'espace, mais modélise l'encombrement physique de la pince (Gripper) à l'aide de 3 points de contrôle virtuels. Cette modélisation permet de détecter si les doigts de la pince vont entrer en collision avec des obstacles (les autres pièces) avant même que le robot ne bouge.

Les trois points sont calculés dans le plan image 2D (pixels) puis projetés en profondeur (Z). Le point P0 (Centre / Cible) est symbolisé par les variables (cx, cy) dans le code. Le rôle de ce point est de représenter le centre de l'objet à saisir (centre du point pivot de la pince). C'est la référence de profondeur (Zref). Ensuit 3 Points P1, P2 et P3 sont ”dessinés“ aux deux extrémités de chaque doigt du gripper. Leur rôle est de représenter la position estimée des pointes des deux doigts de la pince une fois celle-ci orientée selon l'angle de prise calculé et l’ouverture maximale de la pince. Si ses points rencontrent un autre objet la saisie n’est pas valide.

Nudge pour résoudre les situations impossibles

Si tous les objets sont bloqués par des voisins (collision détectée). Le système identifie d’abord l'objet le plus haut (Z max). Il détermine ensuite un vecteur de poussée le long de l'axe mineur de l'objet. Il Vérification l'Espace Libre en deux étapes :

a. Il teste le point de départ A. Si A est obstrué, il tente le côté opposé B.
b. Il vérifie la trajectoire de poussée (Start -> End) dans la carte de profondeur.

Et pour finir le robot effectue un mouvement de balayage (moveL) pour dégager l'objet sans tenter de le saisir, créant ainsi de l'espace pour le cycle suivant.

Ajout des angles en X et Y

Afin de traiter les configurations complexes où les pièces ne reposent pas uniformément à plat notamment en cas de chevauchement ou d'appui instable sur d'autres éléments une stratégie d'adaptation tridimensionnelle a été évaluée. Cette approche vise à intégrer la gestion des rotations selon les axes X et Y (angles Rx et Ry), permettant au préhenseur de s'aligner non plus seulement sur le plan horizontal, mais selon la normale de la surface de l'objet. Le procédé repose sur l'analyse de la carte de profondeur pour estimer l'inclinaison locale de la pièce, données qui sont ensuite transmises au contrôleur pour pré-orienter le poignet du robot avant l'amorce de la descente.

Bien que cette méthode offre une meilleure conformité aux géométries inclinées et permette théoriquement de sécuriser la prise en maximisant la surface de contact,

elle s'est heurtée à des obstacles pratiques rédhibitoires. Outre sa sensibilité au bruit de mesure des capteurs de profondeur, l'application de rotations complexes au poignet impose des contraintes cinématiques sévères qui réduisent considérablement l'espace de travail effectif du bras robotisé. En raison de cette perte d'accessibilité, qui empêchait le robot d'atteindre certaines zones périphériques de la zone de travail sans entrer en butée articulaire ou en singularité, cette fonctionnalité n'a pas été retenue dans l'architecture finale du projet.

Double caméra avec ”contrôle qualité"

Le robot amène l'objet devant la caméra fixe (CAM TO). Il effectue une rotation de l'objet sous la caméra (-90°, 0°, +90°). Il analyse par le second modèle YOLO (model_U_L) la classe de l‘objet : "U" ou "L" et met à jour les compteurs puis effectue la trajectoire jusqu'à la zone de dépôt (DROP_POSE). Cette méthode permet une très haute confiance sur l‘identification du type d‘objet mais allonge considérablement le temps de cycle. De plus, la gestion de deux caméras simultanément complexifie le code et rend les calculs plus lourds.

MoveJ et MoveL rotation/déplacement (4 étapes)

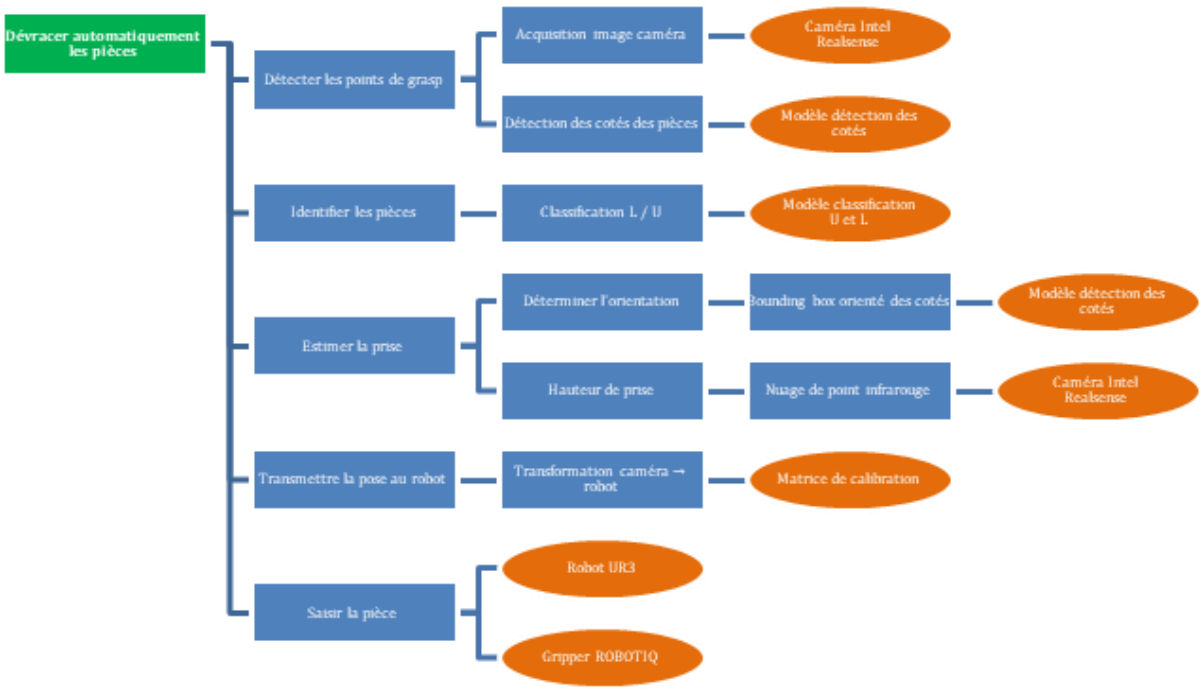
La stratégie définitivement adoptée pour le cycle de préhension repose sur une architecture cinématique hybride, exploitant la complémentarité entre les mouvements articulaires (MoveJ) et cartésiens (MoveL). Cette approche a pour objectif de maximiser la cadence globale du cycle tout en garantissant la rigueur géométrique nécessaire lors des phases critiques d'interaction avec la pièce. Le processus a été structuré pour tirer parti de la rapidité des déplacements articulaires lors des phases de transit, et de la rectitude des trajectoires linéaires lors des phases d'approche finale.

Concrètement, la séquence débute par un mouvement rapide de type MoveJ vers une pose d'approche globale, permettant de rallier la zone de travail sans contrainte de trajectoire stricte. S'ensuit une phase de réorientation pure, toujours en mode articulaire, où seul le poignet est sollicité pour s'aligner sur l'angle de saisie détecté, sans altérer la position spatiale. La transition vers le mode cartésien (MoveL) s'opère exclusivement pour la descente finale et la saisie, garantissant une verticalité parfaite et une maîtrise précise de la profondeur. Enfin, le retrait post-saisie est exécuté par une remontée linéaire sécurisée, prévenant tout risque de collision latérale avec l'environnement encombré du tas à dévraquer. Ce protocole offre un équilibre optimal entre vitesse d'exécution et sécurité opératoire, raison pour laquelle il constitue le standard technique du projet.

Explication du calcul "Hors Vision" (Score = 0)

Le code intègre un mécanisme de filtrage sélectif qui ne se contente pas de vérifier la présence de la pièce dans le champ de vision global, mais s'assure de sa position dans une zone de haute précision nommée « BestWindow ». Sur une résolution native de 640×480 pixels, le système définit une région d'intérêt virtuelle (ROI) centrée sur l'axe optique, délimitée verticalement par les pixels 200 à 340 et horizontalement par les pixels 280 à 440. Cette fenêtre restreinte de 160×140 pixels agit comme un gabarit de tolérance pour valider la qualité de l'alignement robot-caméra après la phase d'approche.

Le fonctionnement repose un système de score de confiance du candidat détecté. Si le centre de gravité de l'objet (cx ,cy) se situe à l'intérieur de cette fenêtre centrale, le système considère que l'alignement est optimal et que la calibration est valide ; le score du candidat est alors doublé pour le prioriser dans la file d'attente. À l'inverse, si l'objet détecté persiste en périphérie de cette zone malgré le mouvement de centrage, cela signale un risque (dérive de calibration ou déplacement inopiné de la pièce). Dans ce cas de figure, une pénalité critique est appliquée en forçant le score à zéro, ce qui exclut automatiquement la pièce de la sélection finale et empêche toute tentative de saisie sur une cible géométriquement instable. Cet ajout permet aussi de garder plus souvent la même prise entre la première estimation et la deuxième estimation, évitant ainsi de tenter la saisie d’un objet hors zone et/ou déjà trié.



4. Axes d'amélioration du TP :

Installation des librairies :

Vérifier avant le début des TP que tous les postes ont les librairies nécessaires à jour et que les mots de passes des sessions sont connus

Fiche de TP :_uiiolujpuh

Une fiche de TP comprenant le cadre et les objectifs du TP, permettant à chaque groupe de comprendre la direction du TP sans l'intervention de l'enseignant poste par poste. Cette fiche de pourrais aussi comprendre les instructions pour accéder à ROS2, comment configurer la connexion au robot (avec des IP différents pour chaque groupe).

Calibration Robot :

Les paramètres pour la calibration sur ROS2 pourraient eux aussi être recensés dans un guide.

Guides pour les librairies à utiliser :

Un guide ou un recueil contenant les librairies à utiliser, leur rôle et les fonctions principales avec leurs arguments pourrais grandement accélérer le processus et permettre de le réaliser dans le temps imparti.

Nombre d'étudiants par groupe :

Faire le TP en demis groupe de classe pour avoir des groupes de 3 maximum

Bibliographie

Arxiv : Densefusion [en ligne]. [ref. du 23 janvier 2026]. Disponible sur : [1901.04780] DenseFusion: 6D Object Pose Estimation by Iterative Dense Fusion

Arxiv : CosyPose [en ligne]. [ref. du 23 janvier 2026]. Disponible sur :[2008.08465] CosyPose: Consistent multi-view multi-object 6D pose estimation